projekt_eda_patryk_kozlowski

May 1, 2026

1 Exploratory Data Analysis cacao dataset na SAD

okej to zacznijmy od zimportowania bibliotek

[1]:
```
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
```

okej teraz dataset wyczyszczony importujemy

[2]:
```
cacao = pd.read_csv('flavors_of_cacao_clean.csv')
```

[3]:
```
cacao.head(5)
```

[3]:
```
     company product_name  reference_id  review_year  cocoa_percent  \
0  A. Morin  Agua Grande          1876         2016           63.0
1  A. Morin        Kpime          1676         2015           70.0
2  A. Morin       Atsane          1676         2015           70.0
3  A. Morin        Akata          1680         2015           70.0
4  A. Morin       Quilla          1704         2015           70.0

  company_location  rating bean_type bean_origin  is_dark rating_grade
0           France    3.75       NaN         NaN    False      Premium
1           France    2.75       NaN         NaN     True     Poprawny
2           France    3.00       NaN         NaN     True     Poprawny
3           France    3.50       NaN         NaN     True      Premium
4           France    3.50       NaN         NaN     True      Premium
```

2 ETAP I

średnia rating

[7]:
```
float(cacao["rating"].mean().round(2))
```

[7]: 3.19

mediana rating

[8]:
```
cacao["rating"].median()
```

[8]: 3.25

odchylenie standardowe rating

[9]:
```
cacao["rating"].std()
```

[9]: 0.47766761134655794

min i max rating

[10]:
```
cacao["rating"].apply(lambda x: round(x, 2)).min(), cacao["rating"].
↪apply(lambda x: round(x, 2)).max()
```

[10]: (1.0, 5.0)

kwartyle rating

[11]:
```
cacao["rating"].quantile([0.25, 0.5, 0.75])
```

[11]:
```
0.25    3.00
0.50    3.25
0.75    3.50
Name: rating, dtype: float64
```

histogram rating

[26]:
```
cacao["rating"].hist()
plt.title("Histogram oceny czekolad")
plt.xlabel("Ocena")
plt.ylabel("Liczba czekolad")
plt.show()
```

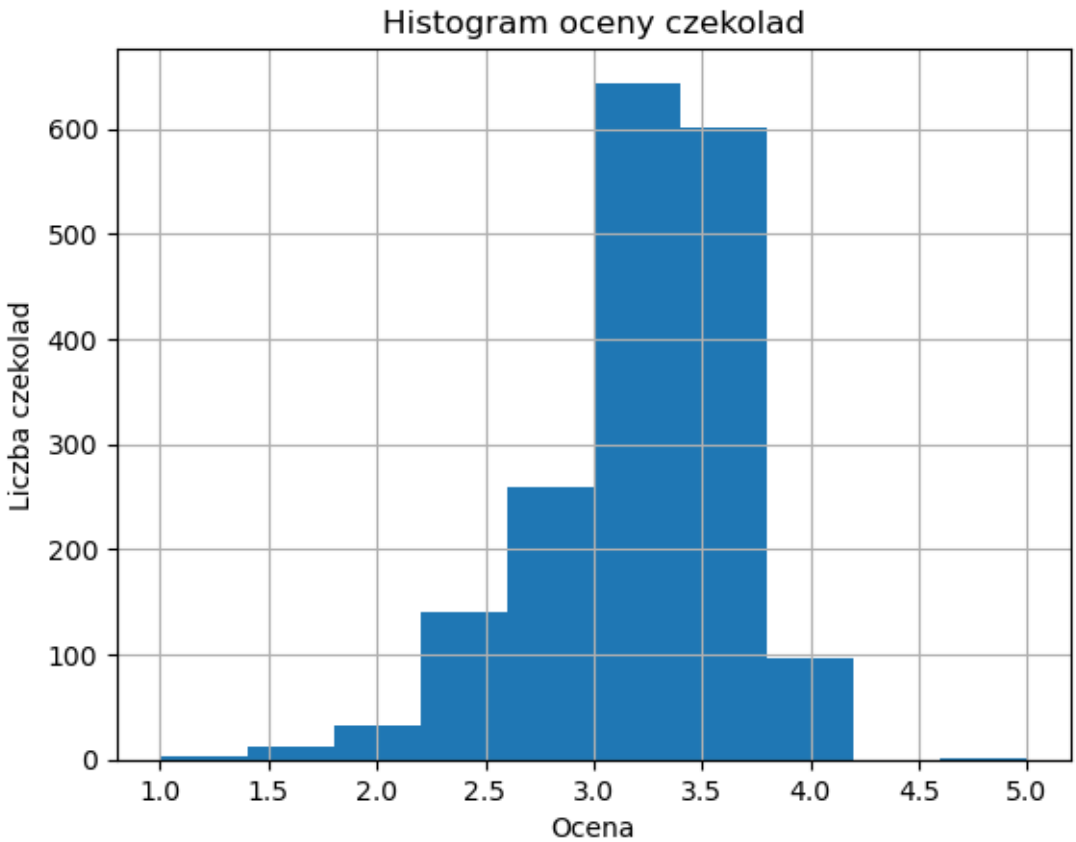

boxplot rating

[17]:
```
cacao["rating"].plot(kind="box")
plt.title("Boxplot oceny czekolad")
plt.show()
```

[17]: <Axes: >

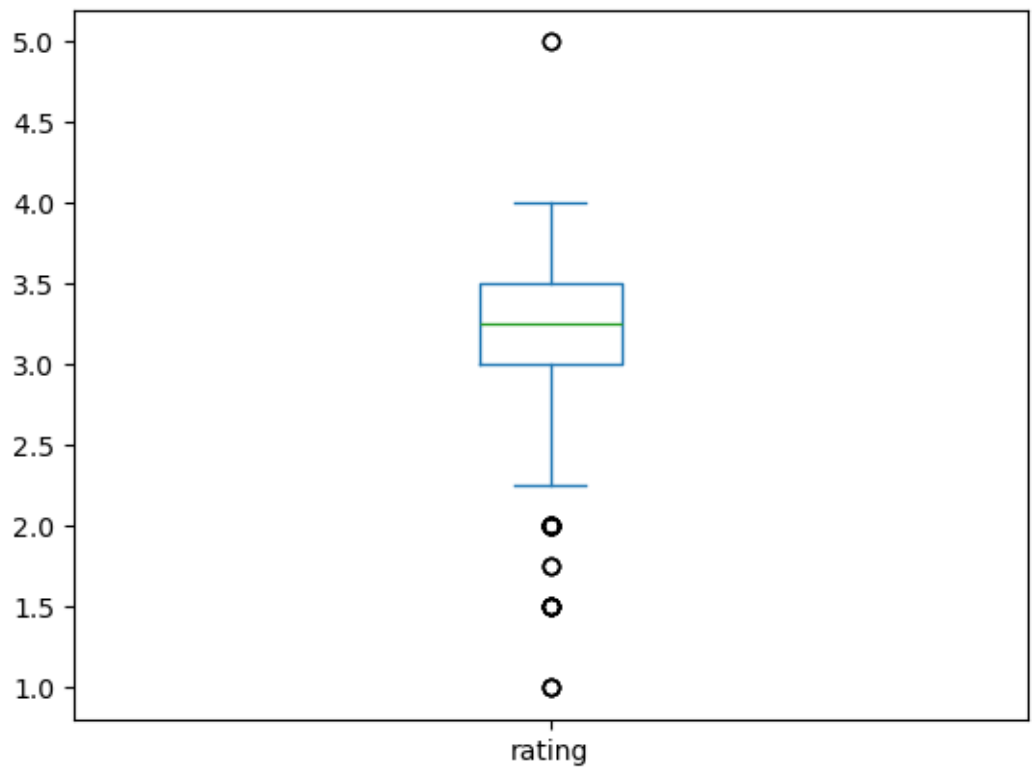

okej jeśli chodzi o krótki opis to rating wygląda tak, że z boxplotu wynika że jest 5 outlinerów, większość z oceną poniżej std, że większość ocen jest między 3.0 a 3.7, roztęp między kwartylami jest dość duży, co sugeruje dużą rozpiętość ocen i średnią jakość czekolad. odchylenie standardowe potwierdza tą hipotezę, charakter rozkładu jest prawie normalny, z lekkim prawoskośnym rozkładem, że jest lekka tendencja do większej jakośći

3 Etap II - EDA

bierzemy pod uwagę marki zależne

1.

[21]:
```
rating_by_country =cacao.groupby("company_location")["rating"].mean().
↪sort_values(ascending=False)

rating_by_country.head(10)
```

[21]:
```
company_location
Chile          3.750000
Amsterdam      3.500000
Netherlands    3.500000
Philippines    3.500000
```

```
Iceland        3.416667
Vietnam        3.409091
Brazil         3.397059
Poland         3.375000
Australia      3.357143
Guatemala      3.350000
Name: rating, dtype: float64
```

[24]:
```
pos = rating_by_country.index.get_loc('Poland') + 1
print(f"Polska jest na miejscu {pos}")
```

```
Polska jest na miejscu 8
```

[25]:
```
rating_by_country.head(10).to_frame().plot(kind="bar", legend=False)
plt.ylabel("Średnia ocena")
plt.title("Średnia ocena czekolad w zależności od kraju pochodzenia firmy")
plt.xticks(rotation=45)
plt.show()
```

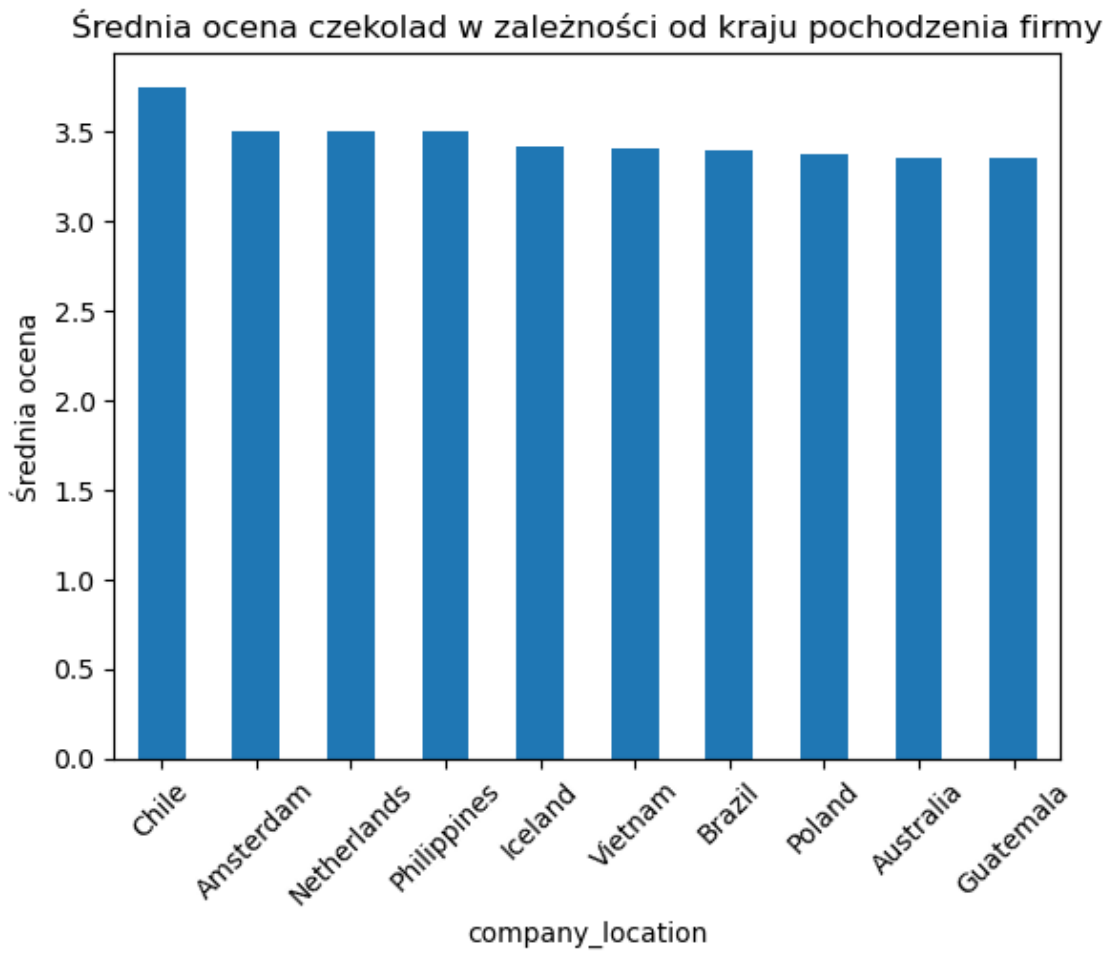

2.

[34]:
```
biggest_country = cacao["company_location"].value_counts()
biggest_country.head(20)
```

[34]:
```
company_location
U.S.A.         763
France         156
Canada         124
U.K.            96
Italy           63
Ecuador         55
Australia       49
Belgium         40
Switzerland     38
Germany         35
Austria         26
Spain           25
Colombia        23
Hungary         22
Venezuela       20
New Zealand     17
Japan           17
Peru            17
Brazil          17
Madagascar      17
Name: count, dtype: int64
```

[31]:
```
biggest_country.head(10).to_frame().plot(kind="bar", legend=False)
plt.ylabel("Liczba czekolad")
plt.title("Liczba czekolad w zależności od kraju pochodzenia firmy")
plt.xticks(rotation=45)
plt.show()
```

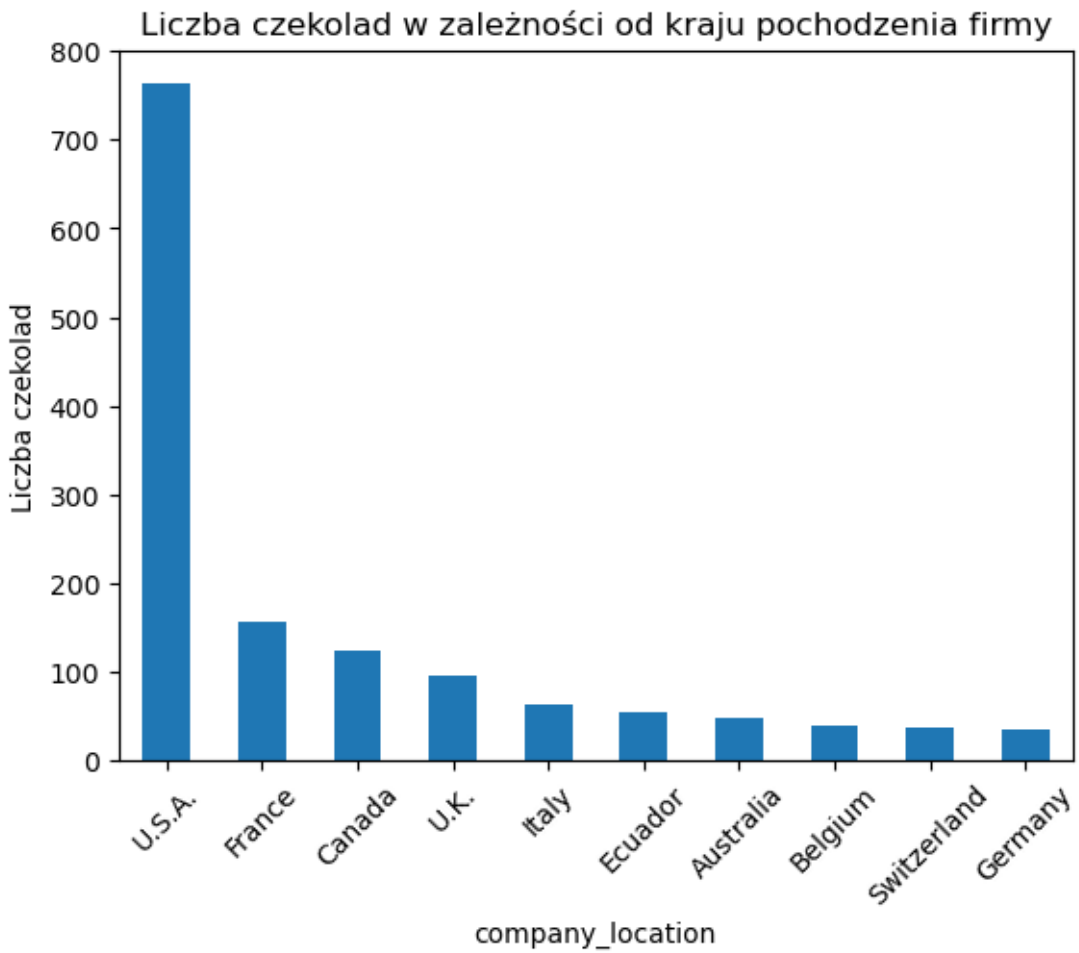

zdecydowanie najwięcej czekolad jest z USA, reszta krajów ma dużo mniej czekolad, Polska jest na 11 miejscu.

4 3.

[52]:
```
print(cacao[["cocoa_percent", "rating"]].corr())
```

```
               cocoa_percent    rating
cocoa_percent       1.000000 -0.164758
rating             -0.164758  1.000000
```

[56]:
```
plt.scatter(cacao["rating"], cacao["cocoa_percent"])
plt.title("Zależność między procentem kakao a oceną czekolady")
plt.xlabel("Procent kakao")
plt.ylabel("Ocena")
plt.show()
```

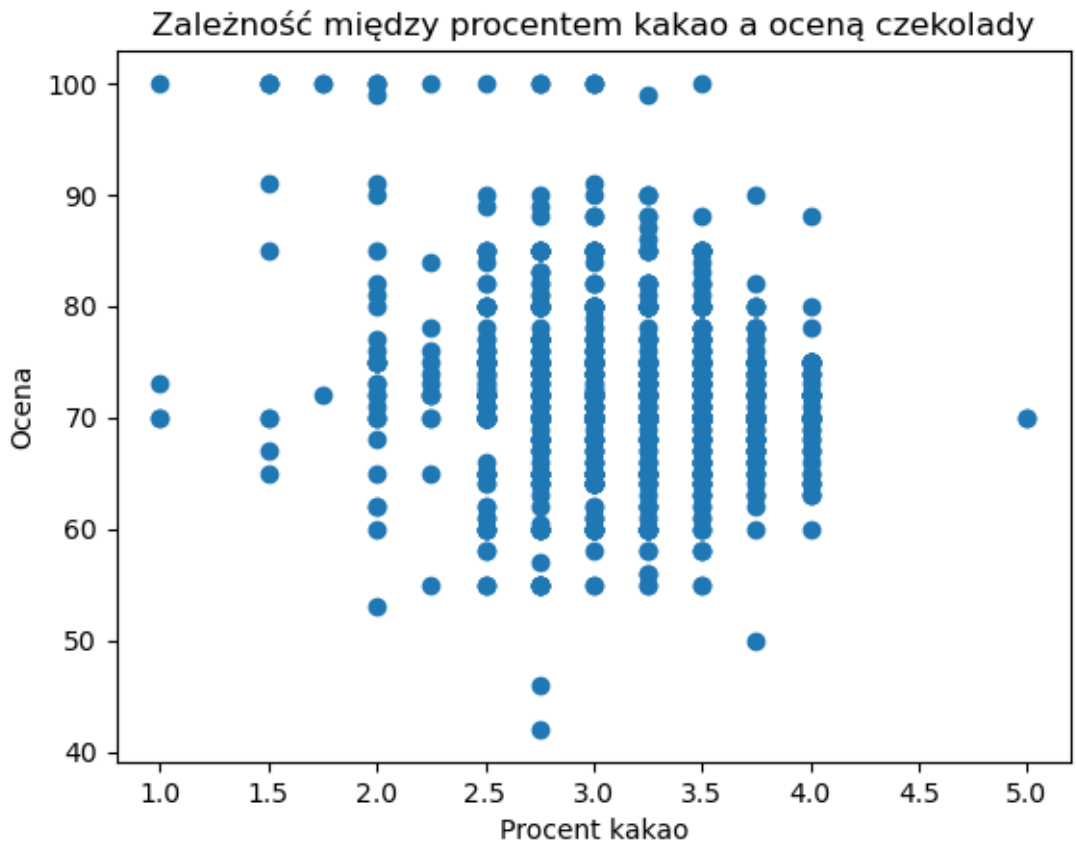

[58]:
```
plt.hexbin(cacao["cocoa_percent"], cacao["rating"], gridsize=20, cmap="Blues")
plt.colorbar(label="count")
plt.title("rozkład gęstości")
```

[58]: Text(0.5, 1.0, 'rozkład gęstości')

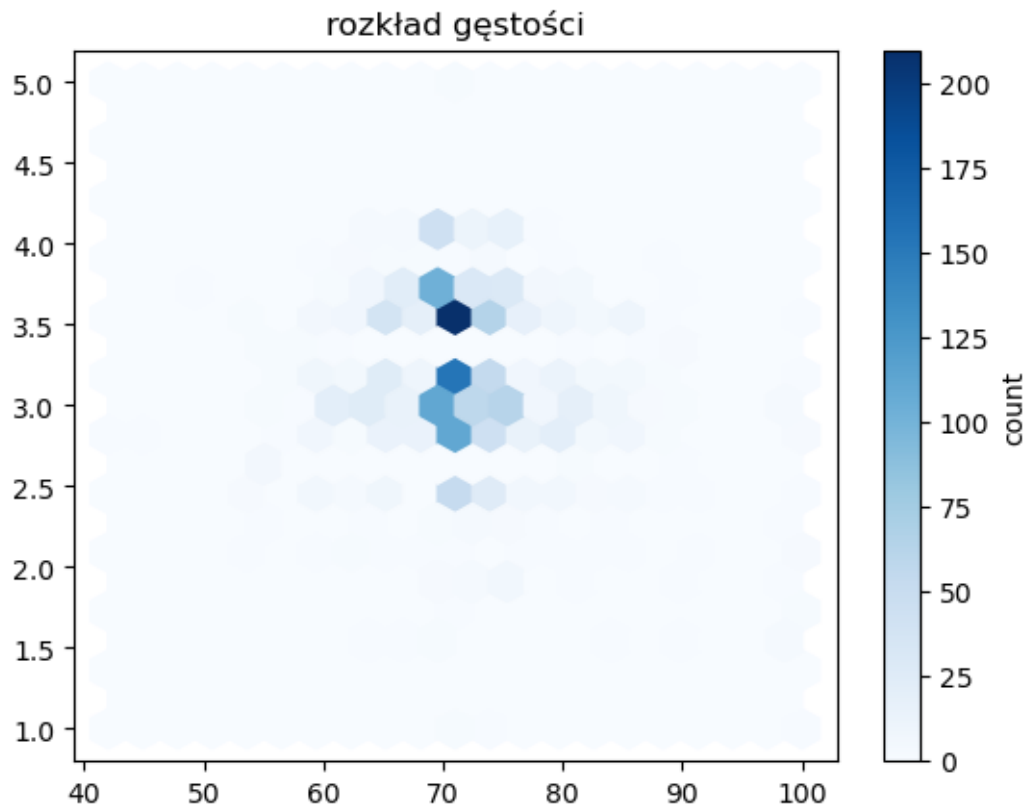

dobra z korelacji wynoszacej -0.164758, co oznacza że jest słaba ujemna korelacja między procentem kakao a oceną czekolady, co sugeruje że wyższy procent kakao może być związany z niższymi ocenami, ale ta zależność jest dość słaba i może być wpływana przez inne czynniki.

5 4.

[33]:
```
cacao["is_dark"].value_counts()
```

[33]:
```
is_dark
True     1465
False     328
Name: count, dtype: int64
```

[41]:
```
valid_countries = biggest_country[biggest_country >= 10].index

plot_df = (
    cacao[cacao["company_location"].isin(valid_countries)]
    .groupby(["company_location", "is_dark"])
    .size()
    .unstack(fill_value=0)
    .sort_index()
```

```
)

plot_df.columns = ["Jasna", "Ciemna"] if set(plot_df.columns) == {False, True}␣
↪else plot_df.columns

plot_df.plot(kind="bar", stacked=True)
plt.ylabel("Liczba czekolad")
plt.title("Liczba czekolad według kraju pochodzenia firmy i rodzaju czekolady")
plt.xticks(rotation=90)
plt.legend(title="Rodzaj")
plt.show()

total_dark = plot_df["Ciemna"].sum() if "Ciemna" in plot_df.columns else␣
↪plot_df[True].sum()
total_light = plot_df["Jasna"].sum() if "Jasna" in plot_df.columns else␣
↪plot_df[False].sum()
```

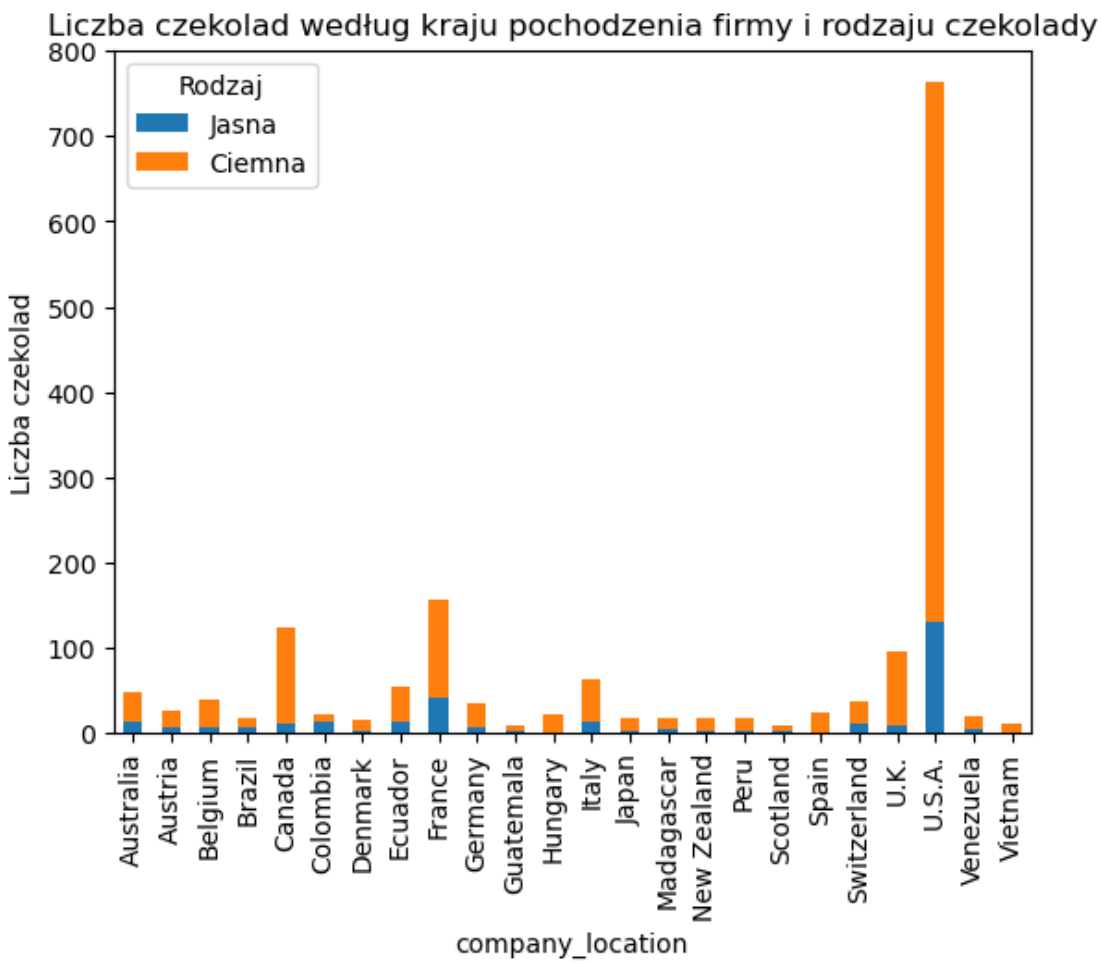

zdecydowanie bardziej popularna jest ciemna czekolada, jest jej 3 razy więcej niż mlecznej

6 5.

Średnia ocena w kolejnych latach

[42]:
```
yearly_mean = cacao.groupby("review_year")["rating"].mean().sort_index()
```

Średnia ocena w kolejnych latach z podziałem na typ czekolady

[44]:
```
yearly_by_type = (
    cacao.groupby(["review_year", "is_dark"])["rating"]
    .mean()
    .unstack()
    .sort_index()
)
```

[45]:
```
yearly_by_type.columns = ["Zwykła", "Gorzka"]

plt.figure(figsize=(10, 5))
plt.plot(yearly_mean.index, yearly_mean.values, marker="o", linewidth=2,␣
 ↪label="Wszystkie")
plt.plot(yearly_by_type.index, yearly_by_type["Zwykła"], marker="o",␣
 ↪label="Zwykła")
plt.plot(yearly_by_type.index, yearly_by_type["Gorzka"], marker="o",␣
 ↪label="Gorzka")

plt.title("Średnia ocena czekolad w kolejnych latach")
plt.xlabel("Rok")
plt.ylabel("Średnia ocena")
plt.xticks(yearly_mean.index, rotation=45)
plt.grid(True, alpha=0.3)
plt.legend()
plt.show()
```

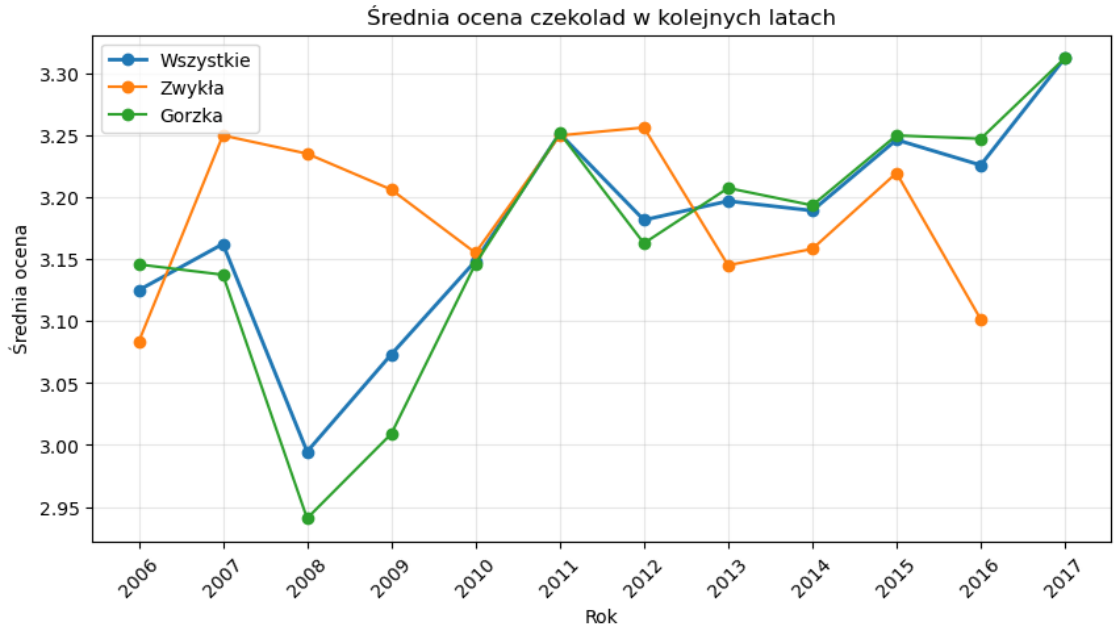

Średnia ocena ogółem w latach

[43]:
```
yearly_mean.round(3)
```

[43]:
```
review_year
2006    3.125
2007    3.162
2008    2.995
2009    3.073
2010    3.149
2011    3.252
2012    3.182
2013    3.197
2014    3.189
2015    3.246
2016    3.226
2017    3.312
Name: rating, dtype: float64
```

7 Wnioski

1. Najwyższą średnią ocenę ma Chile
2. Najwięcej czekolad jest z USA, Polska jest na 11 miejscu
3. Jest słaba ujemna korelacja między procentem kakao a oceną
4. Większość czekolad jest gorzka
5. średnia ocena w kolejnych latach jest dość stabilna, z lekkim wzrostem w ostatnich latach, a

ciemna czekolada ma wyższe oceny niż mleczna.